

人工智能（Artificial Intelligence, AI）是计算机科学的重要分支，目标是让机器具备类似人类的学习、推理和决策能力。

机器学习是人工智能的核心技术之一。它通过大量数据训练模型，使计算机能够自动发现规律并完成预测任务。例如，垃圾邮件识别、人脸识别和推荐系统都属于机器学习的典型应用。

深度学习是机器学习的重要方向，它基于神经网络结构，能够处理图像、语音和自然语言等复杂数据。目前，大语言模型（LLM）已经广泛应用于智能问答、代码生成和文档分析等场景。

RAG（Retrieval-Augmented Generation，检索增强生成）是一种结合知识检索与大语言模型生成能力的技术。它通常包括以下几个步骤：

1. 文档读取
2. 文本切分
3. 向量化（Embedding）
4. 向量数据库存储
5. 相似度检索
6. 大模型生成答案

在 Spring AI 中，可以通过 PdfDocumentReader 读取 PDF 文档，再使用 TextSplitter 对文本进行切分，最后通过 EmbeddingModel 生成向量并存储到 Elasticsearch 或 Milvus 等向量数据库中。

向量数据库能够根据语义相似度快速检索相关内容，因此非常适合构建企业知识库、智能客服和本地 RAG 系统。

Ollama 是一个本地运行大语言模型的工具，可以方便地部署 DeepSeek、Qwen、Llama 和 bge-m3 等模型。开发者可以通过 Spring AI 调用 Ollama 接口，实现本地 AI 应用开发。

随着生成式人工智能的发展，本地知识库与 RAG 技术正在成为 AI 应用的重要基础设施。